Tutoría del 2026-11-11: propuestas de Alejandro y tareas pendientes

Los montos están en millones de pesos por mes (M), con la ganancia de la consigna. Los términos técnicos están al final.

Marco que fijó Alejandro

- **El experimento usa solo meses de 2019.** Alejandro descarta 2020 por la pandemia. 2021 es el período de la competencia 2.
- **El punto de partida es el baseline: lag y delta de 1 y 2 meses.** El experimento busca variables históricas que ganen más que el baseline. La comparación no es contra un modelo sin historia.
- **La meta es una mejora de cerca de 5 % sobre el baseline.** La diferencia tiene que ser significativa con varias semillas. Una mejora menor también sirve, si es significativa. Como referencia, la prueba fijada dio de 1,2 % a 1,9 % sobre `A`.
- **El grupo puede cambiar el baseline.** Por ejemplo, puede cambiar su ventana de entrenamiento si una variante necesita otra ventana.

Propuestas de Alejandro

#	Propuesta	Qué dijo Alejandro	Qué probó el grupo	Qué queda pendiente
1	Ventana de entrenamiento	El baseline y las variantes entrenan con los mismos meses. Ejemplos: desde abril para 3 meses de historia, desde mayo para 4 y desde julio para 6. El estándar de 2019 eran 3 meses. Igual sugiere probar 5 o 6 meses, "aunque quede un solo mes de entrenamiento"	Todas las variantes de la prueba fijada entrenaron con 201905–06. Entrenar solo con los últimos 4 meses disponibles dio Empate (+0,02 M). El grupo no probó lags de 6 meses: en el entrenamiento, el lag 6 no tiene datos	Probar 5 o 6 meses de historia con un solo mes de entrenamiento (201907). **Atención:** en 201907, las variables `*_fultimo_cierre` están rotas

#	Propuesta	Qué dijo Alejandro	Qué probó el grupo	Qué queda pendiente
2	Mínimo, máximo, media móvil y tendencia	Son las variables históricas clásicas. La tendencia es la pendiente de una regresión sobre los últimos meses. El notebook `z402` la calcula con `regr_slope`	Las variantes `T3`, `T4`, `LT3` y `LT4` de la prueba fijada tienen estas cuatro variables. Ninguna cumple la regla pre-registrada. En 201910 ganan de +3,6 a +5,4 M más que `A`. La más cercana a cumplir es `LT3`, con un p de Holm de 0,070	Repetir `T3`, `T4`, `LT3` y `LT4` con hiperparámetros propios (#6)
3	**Rango (máximo menos mínimo)**	**Muestra cuánto cambió el valor del cliente en la ventana. Es fácil de explicar al negocio**	**El grupo no probó el rango**	**Probar la propuesta**
4	Otros cocientes	Ejemplos: el último mes dividido por el promedio de 3 meses, o un mes dividido por el primer mes de la ventana	La historia curada tiene dos cocientes de este tipo: el mes contra el promedio de 3 meses (`ratio3`) y el mes contra su máximo (`relmax4`). La historia curada dio Suma (+4,09 M)	Probar el mes contra el primer mes de la ventana
5	**Solo lags, sin deltas**	**El delta es "súper cuestionable". Un árbol más profundo puede reconstruir el delta a partir de los lags**	**El grupo no probó los lags sin deltas**	**Probar la propuesta**

#	Propuesta	Qué dijo Alejandro	Qué probó el grupo	Qué queda pendiente
6	Reoptimizar los hiperparámetros para cada conjunto de variables	Con 1.500 a 2.000 columnas, el mismo `feature_fraction` elige muchas más variables por árbol. Por eso hay que reoptimizar los hiperparámetros. Según Alejandro, este método es correcto: el experimento evalúa la estrategia de sumar variables	La prueba fijada usó los hiperparámetros de `A` para todas las variantes. Reoptimizar sobre la estrategia final dio Empate (−0,92 M). Reoptimizar para A-consigna no mejoró A-consigna	Reoptimizar cada variante de la prueba fijada. Después, repetir la comparación
7	Cortar variables correlacionadas	Muchas variables parecidas tienen mucha correlación. Hay tres opciones: cortar variables con canaritos, cortarlas con otro método o dejarlas todas	La selección con canaritos sobre la estrategia final dio Empate (−0,79 M). El grupo descartó la selección con canaritos	Ninguna prueba nueva

#	Propuesta	Qué dijo Alejandro	Qué probó el grupo	Qué queda pendiente
8	Convertir los montos en rankings	La inflación cambia el valor de los montos. Por eso conviene convertir los montos en rankings antes de calcular la historia	En la prueba fijada, `LT4` sobre rankings ganó +8,6 M más que `A` sobre rankings. Pero `A` sobre rankings perdió −7,9 M contra `A`: es un control débil. Los rankings con cero fijo de Tomás dieron Resta (−1,76 M), dentro del segundo paquete. El grupo descartó el ajuste por IPC (índice de precios al consumidor) sin probarlo	Definir qué ranking usar. Definir contra qué baseline comparar
9	Desvío estándar	El desvío es "veneno". Aparece entre las variables más importantes, pero es difícil de explicar al negocio. Alejandro prefiere el rango	La estrategia final ya tiene el desvío, en `std3` y en `z4`	Ninguna prueba nueva. Al presentar la estrategia final, explicar también `std3` y `z4`
10	Pensar a futuro	En la competencia 2 habrá más meses. Conviene una estrategia que gane más con más meses de entrenamiento	Ninguna prueba directa. El segundo paquete da una pista: perdió −8,07 M con 2 meses de entrenamiento y ganó +1,78 M con 6	Tener en cuenta esta pista en la competencia 2

Propuesta del grupo: promedio ponderado. Tomás probó un promedio que da más peso a los últimos meses. Según lo dicho en la tutoría, el promedio ponderado no mejoró. El registro del grupo no tiene la definición ni el resultado.

Tareas pendientes para el equipo

Las tareas van en orden. Cada tarea depende de la anterior.

1. **Decidir si el grupo retoma los experimentos sobre 2019.** Las propuestas #1, #3, #4, #5 y #6 necesitan experimentos nuevos.
2. **Acordar cómo presentar los resultados nuevos.** El grupo ya usó todos los meses de 2019. Por eso, todo resultado nuevo es exploratorio. El resultado de la prueba fijada no cambia.
3. **Elegir una ventana de entrenamiento común** para el baseline y las variantes (#1).
4. **Definir las variables nuevas** con el notebook `z402_Feature_Engineering_en_SQL.ipynb` (#1, #3, #4 y #5):
   - el rango;
   - los lags sin deltas;
   - el mes contra el primer mes de la ventana;
   - 5 o 6 meses de historia.
5. **Reoptimizar los hiperparámetros para cada variante** (#6). Comparar cada variante con el baseline con varias semillas. Buscar una diferencia significativa.
6. **Decidir si el grupo convierte los montos en rankings** (#8).
7. **Registrar el promedio ponderado.** Tomás comparte la definición y el resultado.

Términos

Término	Qué es
Baseline	El modelo de referencia de la consigna: lag y delta de 1 y 2 meses. El grupo lo implementó con dos ventanas: `A` y A-consigna
`A`	El baseline con la ventana 201905–06: 760 columnas. Es el control de la prueba fijada
A-consigna	El baseline con la ventana de la consigna (201903–06): las mismas 760 columnas
Ventana de entrenamiento	Los meses con los que entrena el modelo
Variante	Un modelo que agrega variables al baseline
Prueba fijada	La comparación del notebook 04. El grupo escribió la regla antes de ver los resultados: Wilcoxon con corrección de Holm, 10 semillas, octubre de 2019
`T3`, `T4`	`A` más tendencias de 3 o 4 meses: pendiente, promedio, mínimo y máximo
`LT3`, `LT4`	`A` más lags y tendencias de 3 o 4 meses
Historia curada	Cuatro columnas que comparan a cada cliente con su propio pasado: `ratio3`, `z4`, `relmax4` y `mes_ratio3`. El grupo las calcula sobre las 30 variables más importantes

Término	Qué es
Estrategia final	La historia curada, más cuatro bloques de historia, Visa y Master combinadas y los cambios relativos de Tomás. `BAJA+2` tiene peso 3. Gana +9,00 M por mes más que A-consigna. Esta ganancia probablemente está inflada
Segundo paquete	960 columnas más sobre la estrategia final: historial del puntaje, hojas de Random Forest, rankings, cruce de Visa y Master y sueldo sin aguinaldo
Ranking	La posición del cliente dentro del mes, en lugar del monto en pesos
Suma / Empate / Resta	Los veredictos de las comparaciones desde el notebook 15
`z402`	El notebook de la cátedra sobre feature engineering en SQL (`monday/z402_Feature_Engineering_en_SQL.ipynb`)

Medias móviles: diez semillas

Señal pequeña en AUC; sin mejora de ganancia. La media usa los valores disponibles del cliente en el mes actual y los dos anteriores, con un mínimo de dos valores finitos. Se agregó a 129 montos/conteos del PAQ_P3 reproducido: 1.782 columnas en total.

Mismos meses junio-octubre, ventanas de entrenamiento, pesos, hiperparámetros y 296 árboles. Cinco semillas originales y cinco adicionales por brazo. La ampliación a veinte permanece cancelada.

Comparación contra PAQ_P3, total diez

Indicador	Resultado
Ganancia en banda, delta medio	-0,0207 M/mes; IC 95 % [-1,3527; +1,3112]
Semillas favorables en ganancia	4 de 10
AUC, delta medio	+0,000428; favorable en 9 de 10 semillas
AUC, IC entre semillas	[+0,000106; +0,000750] (solo variación algorítmica)
Ensamble de probabilidades	Delta banda +0,0224 M/mes; delta AUC +0,000424

Qué implica

La AUC mejora levemente de forma consistente entre semillas sobre estos mismos datos. Ese cambio no se traduce en más dinero en la banda de 3.000 a 6.000 contactos. **Se conserva MAIN y se cierra esta prueba en diez semillas.** No pasa la regla del pipeline.

El IC de AUC resume la variación entre semillas y no incluye incertidumbre de clientes ni meses futuros. El IC de ganancia es el del pipeline y combina componentes de clientes y semillas. La ampliación fue posterior a mirar las primeras cinco semillas: todo sigue siendo exploratorio.

Qué cambió al ampliar

Grupo	Delta banda M/mes	IC 95 % banda M	Delta AUC
Originales (5)	-0,3400	[-2,4933; +1,8133]	+0,000246
Adicionales (5)	+0,2986	[-1,5211; +2,1183]	+0,000610
Total (10)	-0,0207	[-1,3527; +1,3112]	+0,000428

Diferencias por mes, total diez

Mes	Delta banda M	Delta AUC
201906	-1,0983	-0,000017
201907	+0,7699	+0,000659
201908	-0,5373	+0,000693
201909	+1,2192	+0,000760
201910	-0,4570	+0,000045

Controles y respaldo

Se validaron las 50 predicciones importadas y quedaron 100 finales, 50 por brazo. Las nueve huellas de bloques y las firmas de estrategia permanecen iguales. El subconjunto original reproduce la ganancia y AUC anteriores. Se conservaron métricas exactas, deltas por semilla, grupos, predicciones, código y hashes.

El respaldo final fue comprobado y la VM quedó en **TERMINATED**. Rama: feat/medias-moviles-3m. Protocolo: cb87b1d. Evidencia local: resultados/medias_moviles_3m_10semillas_20261112.

Referencia del baseline: PAQ_P3 da +9,00 M/mes contra AC con ventana reciente común y +12,60 M contra A_CONSIGNA. Esas ganancias no son el aporte de las medias móviles.

Optuna sobre PAQ_P3

Se optimizaron seis hiperparámetros del baseline de Ezequiel. La búsqueda completó **30 pruebas con dos semillas** en junio-agosto. Las tres mejores se reevaluaron con cinco semillas adicionales. La prueba 27 fue elegida y congelada para evaluar septiembre-octubre con diez semillas.

Resultado de la evaluación final

Indicador	Resultado contra PAQ_P3
Ganancia de banda media	+0,5663 M/mes
IC 95 % de ganancia	[-2,5689, +3,7016] M/mes
Semillas favorables en ganancia	6 de 10
Delta AUC media	+0,00102112, favorable en 10 de 10 semillas
Delta ganancia del ensamble	+0,3337 M/mes

La diferencia media de ganancia es positiva y su intervalo incluye cero. La mejora económica queda incierta. La AUC presenta una mejora consistente entre las semillas evaluadas sobre estos mismos datos.

Diferencias por mes

Mes	Delta ganancia M	Delta AUC
201909	+1,3801	+0,00179063
201910	-0,2475	+0,00025161

Todos los meses de 2019 ya habían sido consultados. Esta evaluación se mantuvo separada de la nueva búsqueda y selección. El resultado sigue siendo exploratorio.

Selección y configuración

Prueba	Búsqueda M/mes	Delta reevaluación M/mes
28	254,5019	-0,6356
27	254,3704	+0,3845
21	253,8999	-1,4984

La prueba 27 obtuvo +0,3845 M/mes en reevaluación y fue la elegida por la regla fijada. Se conservaron las 1.653 columnas, el peso BAJA+2 igual a 3 y las ventanas del pipeline.

Parámetro	Valor elegido	Rango explorado
num_leaves	113	24-128, logarítmico
min_data_in_leaf	1852	200-3000, logarítmico
learning_rate	0.01391671	0,005-0,05, logarítmico
feature_fraction	0.29874912	0,20-0,90
bagging_fraction	0.75607051	0,50-1,00
Árboles	451	150-900, logarítmico

Los límites de búsqueda fueron fijados por Codex alrededor del baseline antes de entrenar y comunicados a Tomás. Optuna usó TPE secuencial con semilla 979201.

Auditoría y operación

El preflight verificó ocho bloques y cincuenta predicciones. La primera prueba volvió a entrenar seis modelos de PAQ_P3 y reprodujo sus predicciones bit a bit. La auditoría local verificó métricas, pares y SHA256 del código transferido a GCP.

La corrida entrenó 245 modelos en 6.85 horas. Código de salida cero, respaldo final comprobado y VM en TERMINATED. Rama feat/optuna-paq-p3, protocolo 30ef0c3. Evidencia local en resultados/optuna_paq_p3_20261113/.